

Università degli Studi di Milano Bicocca
Scuola di Scienze
Dipartimento di Informatica, Sistemistica e Comunicazione

Metodi del Calcolo Scientifico

Progetto 1

Mini libreria di solutori iterativi per sistemi lineari
simmetrici e definiti positivi

Relazione

Autori

Matias Bonoli – matricola 912941
Ashley Chudory – matricola 935003
Daniele Maccagnan – matricola 945269

Anno Accademico 2025–2026

Indice

1	Introduzione	2
2	Linguaggio e librerie	2
2.1	Ambiente di esecuzione	2
3	I quattro metodi	3
3.1	Criterio di arresto	3
3.2	Schema comune: lo splitting	3
3.3	Metodo di Jacobi	3
3.4	Metodo di Gauss–Seidel	4
3.5	Metodo del Gradiente	4
3.6	Metodo del Gradiente coniugato	4
3.7	Architettura della libreria	5
4	Risultati ed esperimenti	5
4.1	Procedura	5
4.2	Le matrici di test	6
4.3	Tabelle complete dei risultati	6
4.4	Numero di iterazioni	8
4.5	Errore relativo	10
4.6	Tempo di calcolo	12
4.7	Storia di convergenza	14
4.8	Iterazioni e numero di condizionamento	15
4.9	Costo medio per iterazione	15
4.10	Amplificazione errore/residuo	16
4.11	Riepilogo	17
5	Conclusioni	18
6	Documentazione	19
6.1	Modulo <code>solvers.py</code>	19
6.2	Modulo <code>run_assignment.py</code>	20
6.3	Modulo <code>plots.py</code>	20
6.4	Modulo <code>test_assignment.py</code>	20
6.5	Esecuzione	20
7	Codice	21
7.1	<code>solvers.py</code>	21
7.2	<code>run_assignment.py</code>	25
7.3	<code>plots.py</code>	28
7.4	<code>test_assignment.py</code>	34

1 Introduzione

Lo scopo del progetto è scrivere una piccola libreria che risolve sistemi lineari

$$A\mathbf{x} = \mathbf{b}$$

con quattro metodi iterativi: Jacobi, Gauss–Seidel, Gradiente e Gradiente coniugato. La libreria si limita al caso in cui la matrice A è simmetrica e definita positiva (SPD). I quattro metodi sono scritti da zero: la libreria di base serve solo per la struttura dati della matrice e per le operazioni elementari (prodotto matrice–vettore, somma di vettori, prodotto scalare, norma), mentre la parte che calcola la soluzione del sistema è interamente nostra.

Il lavoro segue la procedura standard di validazione. Per ogni matrice di test si fissa la soluzione esatta $\mathbf{x} = [1, 1, \dots, 1]$, si costruisce il termine noto $\mathbf{b} = A\mathbf{x}$, si risolve il sistema con i quattro metodi e si misura, per ciascuno, l’errore relativo rispetto alla soluzione esatta, il numero di iterazioni e il tempo di calcolo. La prova è ripetuta per le quattro tolleranze richieste, $\text{tol} = 10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$, sempre sullo stesso calcolatore.

La relazione è organizzata così. Prima elenchiamo il linguaggio e le librerie usate. Poi descriviamo i quattro metodi, sul piano teorico e su quello implementativo, e spieghiamo l’architettura della libreria. Quindi raccogliamo i risultati sperimentali in tabelle e grafici, con l’analisi sotto ognuno, e chiudiamo con le conclusioni. In fondo ci sono la documentazione d’uso e il codice sorgente completo.

2 Linguaggio e librerie

Il progetto è scritto in Python 3.12. Tutti i pacchetti usati sono open source:

- **numpy**: array e operazioni vettoriali, cioè prodotto scalare, norma euclidea e aggiornamenti elemento per elemento;
- **scipy.sparse**: struttura dati della matrice in formato sparso CSR e prodotto matrice–vettore Av ;
- **scipy.io.mmread**: lettura dei file in formato MatrixMarket `.mtx`;
- **numba**: compilazione JIT della sola *sweep* di Gauss–Seidel, che è sequenziale e quindi non si può vettorizzare; resta comunque codice nostro;
- **matplotlib**: generazione dei grafici;
- **scipy.sparse.linalg.eigsh**: usato per la stima gli autovalori estremi.

La traccia chiede di non usare i solutori già pronti della libreria di base. La regola che abbiamo seguito è semplice: di **scipy** usiamo solo la lettura del file, il contenitore sparso CSR e il prodotto matrice–vettore. Nessun metodo che risolve un sistema lineare viene dalla libreria. Il formato sparso è necessario perché le matrici di test hanno migliaia di righe e salvarle per intero costerebbe troppa memoria. Il formato CSR memorizza solo le entrate diverse da zero, e il prodotto Av costa quanto il numero di entrate non nulle invece di $O(n^2)$.

2.1 Ambiente di esecuzione

Tutte le prove sono state eseguite sullo stesso calcolatore, con le caratteristiche e le versioni riportate nella tabella seguente. I tempi di calcolo vanno letti in questo contesto: contano i rapporti tra i metodi, non i valori assoluti, che dipendono dalla macchina.

Tabella 1: Ambiente di esecuzione degli esperimenti.

Processore	Apple M4 (10 core)
Memoria	16 GB
Sistema operativo	macOS 26.5
Python	3.12
Librerie	numpy 2.4, scipy 1.17, numba 0.65, matplotlib 3.10

3 I quattro metodi

In questa sezione descriviamo i metodi sul piano teorico e su quello implementativo. Conviene partire da ciò che hanno in comune: il criterio di arresto e lo schema generale di iterazione.

3.1 Criterio di arresto

Tutti i metodi partono dal vettore iniziale nullo $\mathbf{x}^{(0)} = \mathbf{0}$ e costruiscono una successione $\mathbf{x}^{(k)}$ che si avvicina alla soluzione. Non potendo usare la soluzione esatta per fermarsi, si usa il residuo scalato. L'iterazione si arresta quando

$$\frac{\|\mathbf{b} - A\mathbf{x}^{(k)}\|}{\|\mathbf{b}\|} < \text{tol}.$$

Il numeratore è il residuo $\mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}$. Se è piccolo, allora $A\mathbf{x}^{(k)} \approx \mathbf{b}$, cioè $\mathbf{x}^{(k)}$ risolve il sistema con la precisione richiesta. Si divide per $\|\mathbf{b}\|$ per rendere la quantità adimensionale. Oltre a questo controllo c'è un limite sul numero di iterazioni: se si supera `maxIter` il metodo si ferma e segnala di non aver raggiunto la convergenza. Abbiamo fissato `maxIter` = 20000.

3.2 Schema comune: lo splitting

I primi due metodi, Jacobi e Gauss-Seidel, sono metodi stazionari basati su uno *splitting* della matrice. Si scrive

$$A = P - N,$$

e si riscrive il sistema come $P\mathbf{x} = N\mathbf{x} + \mathbf{b}$, da cui la formula iterativa

$$\mathbf{x}^{(k+1)} = P^{-1}N\mathbf{x}^{(k)} + P^{-1}\mathbf{b}.$$

L'idea è scegliere P in modo che il sistema con matrice P sia facile da risolvere. Manipolando questa formula si ottiene la forma che usiamo nel codice,

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + P^{-1}\mathbf{r}^{(k)}, \quad \mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}.$$

Il metodo si dice stazionario perché le matrici P e N non dipendono dall'iterazione k . La convergenza è garantita quando il raggio spettrale della matrice di iterazione $P^{-1}N$ è minore di 1. Per matrici SPD questo è sempre vero per Gauss-Seidel. Per Jacobi invece non è garantito in generale: vale ad esempio se la matrice è a dominanza diagonale stretta. Sulle quattro matrici di test entrambi i metodi convergono.

3.3 Metodo di Jacobi

Si prende come P la diagonale di A e come N il resto con segno opposto. La i -esima componente si aggiorna isolando x_i dalla i -esima equazione e usando i valori dell'iterazione precedente:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right).$$

Dato che P è diagonale, la sua inversa è immediata e $P^{-1}\mathbf{r}$ è solo il prodotto componente per componente fra il residuo e i reciproci della diagonale. Nel codice calcoliamo questi reciproci una volta sola, all'inizio, e a ogni passo aggiorniamo `x += inv_diag * residual` con una operazione vettoriale, senza cicli `for` di Python; poi ricalcoliamo il residuo con `residual = b - A @ x`. Una iterazione costa quindi un prodotto matrice-vettore più operazioni di ordine $O(n)$.

3.4 Metodo di Gauss-Seidel

Si prende come P la parte triangolare inferiore di A , diagonale compresa. La differenza rispetto a Jacobi è che, quando si calcola $x_i^{(k+1)}$, si usano subito i valori già aggiornati in questa stessa iterazione per gli indici $j < i$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij} x_j^{(k+1)} - \sum_{j>i} a_{ij} x_j^{(k)} \right).$$

Non si calcola mai P^{-1} : dato che P è triangolare inferiore, il sistema $P\mathbf{y} = \mathbf{r}$ si risolve per sostituzione in avanti. Questa sostituzione è sequenziale, perché x_i dipende dai valori $x_0, \dots, x_{i-1}$ appena calcolati, e quindi non si può vettorizzare. Per non pagare un ciclo `for` lento in Python l'abbiamo scritta in una funzione compilata con `numba`, `_gauss_seidel_sweep`, che lavora direttamente sugli array CSR (`indptr`, `indices`, `data`); resta comunque codice nostro, perché `numba` traduce il ciclo in linguaggio macchina ma non risolve il sistema al posto nostro. Dopo la sweep ricalcoliamo il residuo per il criterio di arresto. Anche qui una iterazione costa $O(\text{nnz})$, ma l'uso immediato dei valori aggiornati di solito fa convergere in meno iterazioni di Jacobi.

3.5 Metodo del Gradiente

Per matrici SPD risolvere $A\mathbf{x} = \mathbf{b}$ equivale a cercare il minimo della forma quadratica

$$\phi(\mathbf{y}) = \frac{1}{2} \mathbf{y}^t A \mathbf{y} - \mathbf{b}^t \mathbf{y}, \quad \nabla \phi(\mathbf{y}) = A\mathbf{y} - \mathbf{b}.$$

Il gradiente cambiato di segno coincide con il residuo, quindi la direzione di massima discesa è proprio $\mathbf{r}^{(k)}$. Ci si muove lungo questa direzione di un passo α_k scelto in modo da minimizzare ϕ lungo la retta:

$$\alpha_k = \frac{(\mathbf{r}^{(k)})^t \mathbf{r}^{(k)}}{(\mathbf{r}^{(k)})^t A \mathbf{r}^{(k)}}, \quad \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{r}^{(k)}.$$

Il passo cambia a ogni iterazione, quindi il metodo non è stazionario. Nel codice calcoliamo una sola volta per iterazione il prodotto $A\mathbf{r}^{(k)}$ e lo riusiamo sia per α_k sia per aggiornare il residuo senza un secondo prodotto matrice-vettore, $\mathbf{r}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k A\mathbf{r}^{(k)}$; questa è la stessa quantità che serve al criterio di arresto, quindi il residuo è già disponibile. Il metodo converge per ogni dato iniziale, ma il numero di iterazioni cresce con il numero di condizionamento di A : quando gli autovalori sono molto diversi la discesa procede a zig-zag e servono molti passi.

3.6 Metodo del Gradiente coniugato

Il difetto del gradiente è che può tornare a muoversi lungo una direzione su cui era già ottimale, da cui lo zig-zag. Il gradiente coniugato sceglie le direzioni $\mathbf{d}^{(k)}$ in modo che siano A -coniugate, cioè $(\mathbf{d}^{(i)})^t A \mathbf{d}^{(j)} = 0$ per $i \neq j$; così, una volta minimizzato lungo una direzione, non serve più tornarci. La direzione nuova è il residuo corretto con la direzione precedente:

$$\alpha_k = \frac{(\mathbf{r}^{(k)})^t \mathbf{r}^{(k)}}{(\mathbf{d}^{(k)})^t A \mathbf{d}^{(k)}}, \quad \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)},$$

$$\beta_k = \frac{(\mathbf{r}^{(k+1)})^t \mathbf{r}^{(k+1)}}{(\mathbf{r}^{(k)})^t \mathbf{r}^{(k)}}, \quad \mathbf{d}^{(k+1)} = \mathbf{r}^{(k+1)} + \beta_k \mathbf{d}^{(k)}.$$

In aritmetica esatta il metodo converge in al più n iterazioni; in pratica il numero di iterazioni cresce circa come $\sqrt{\text{cond}(A)}$, molto meno del gradiente semplice. Come per il gradiente, nel codice si calcola un solo prodotto matrice–vettore per iterazione, $A\mathbf{d}^{(k)}$, riusato per α_k e per aggiornare il residuo; teniamo da parte $\|\mathbf{r}^{(k)}\|^2$ così che β_k e il valore del residuo per il criterio di arresto non costino calcoli aggiuntivi.

3.7 Architettura della libreria

La traccia chiede una libreria strutturata, non una sequenza di funzioni scollegate. I quattro metodi condividono lo stesso scheletro: partono da $\mathbf{x}^{(0)} = \mathbf{0}$, ripetono un passo di aggiornamento, controllano il residuo scalato e si fermano per convergenza o per numero massimo di iterazioni. L'unica cosa che cambia da un metodo all'altro è la regola di aggiornamento e come si calcola il residuo.

Abbiamo quindi scritto lo scheletro una volta sola. La classe base astratta `IterativeSolver` contiene il metodo `solve`, che gestisce il vettore iniziale, il ciclo di arresto, la misura del tempo e l'eventuale storia del residuo. Ogni passo è incapsulato in un oggetto `_Iteration`, una classe astratta con due soli metodi: `residual_norm()`, che dà $\|\mathbf{r}^{(k)}\|$, e `step()`, che porta $\mathbf{x}^{(k)}$ in $\mathbf{x}^{(k+1)}$. Ogni metodo è una sottoclasse che fornisce solo la propria iterazione. Il risultato di una risoluzione è raccolto in un oggetto `SolverResult` con metodo, soluzione, iterazioni, tempo, residuo raggiunto e flag di convergenza. I quattro solutori sono raccolti nella tupla `SOLVERS` nell'ordine della traccia. Prima delle misure di tempo chiamiamo `warmup()`, che esegue i metodi su un problema 3×3 per pagare una volta sola la compilazione JIT di `numba` e non falsare i tempi.

Costo per iterazione. In tutti e quattro i metodi il costo di una iterazione è dominato da un prodotto matrice–vettore, $O(\text{nnz})$, più operazioni vettoriali $O(n)$. La differenza pratica è che Jacobi e Gauss–Seidel ricalcolano il residuo con un prodotto $A\mathbf{x}$ esplicito a fine passo, mentre Gradiente e Gradiente coniugato ottengono il residuo aggiornato per ricorsione, riusando il prodotto già fatto per il passo. Il numero totale di iterazioni dipende invece molto dal metodo e dal condizionamento della matrice, ed è qui che i metodi si distinguono davvero.

4 Risultati ed esperimenti

Tutti i contenuti prodotti dagli script sono raccolti nella cartella **results**: il file `results.csv` con le misure numeriche, il file `cond.csv` con i numeri di condizionamento e la cartella `plots` con i grafici. In questa sezione li riportiamo tutti, con un'analisi sotto ognuno.

4.1 Procedura

La procedura è quella di validazione standard, eseguita sullo stesso calcolatore descritto nella sezione iniziale. Per ogni matrice si fissa la soluzione esatta $\mathbf{x} = [1, 1, \dots, 1]$, si costruisce il termine noto $\mathbf{b} = A\mathbf{x}$, si risolve il sistema con i quattro metodi a partire da $\mathbf{x}^{(0)} = \mathbf{0}$ e si misura, per ognuno, il numero di iterazioni, il tempo e l'errore relativo rispetto alla soluzione esatta, definito come

$$E_{\text{rel}} = \frac{\|\mathbf{x}_{\text{calc}} - \mathbf{x}\|}{\|\mathbf{x}\|},$$

dove $\mathbf{x}_{\text{calc}}$ è la soluzione calcolata dal metodo. È bene chiarire che questa quantità si può calcolare solo perché qui conosciamo la soluzione esatta $\mathbf{x}$, dato che siamo noi a costruirla. In un problema reale $\mathbf{x}$ è ignota e questo errore non è calcolabile. Per questo i metodi si fermano sul residuo scalato, che invece è sempre disponibile. La prova è ripetuta per le quattro tolleranze $10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$.

4.2 Le matrici di test

La tabella seguente riassume le quattro matrici, con dimensione, numero di entrate non nulle, densità e gli autovalori estremi stimati con `analyze_cond.py`. I dati vengono dal file `cond.csv`.

Tabella 2: Matrici di test. La densità è nnz/n^2 . Gli autovalori e il numero di condizionamento $\kappa(A) = \lambda_{\max}/\lambda_{\min}$ sono stimati numericamente.

Matrice	n	nnz	densità	$\lambda_{\min}$	$\lambda_{\max}$	$\kappa(A)$
spa1.mtx	1000	182 434	18.2%	$4.88 \cdot 10^{-1}$	$9.99 \cdot 10^2$	$2.05 \cdot 10^3$
spa2.mtx	3000	1 633 298	18.1%	2.12	$3.00 \cdot 10^3$	$1.41 \cdot 10^3$
vem1.mtx	1681	13 385	0.47%	$1.23 \cdot 10^{-2}$	4.00	$3.25 \cdot 10^2$
vem2.mtx	2601	21 225	0.31%	$7.89 \cdot 10^{-3}$	4.00	$5.07 \cdot 10^2$

Ci sono due famiglie diverse. Le matrici **spa** sono di media densità, circa il 18% di entrate non nulle, con autovalore massimo grande. Le matrici **vem** sono molto sparse, sotto lo 0.5%, con autovalore massimo limitato a 4 ma autovalore minimo molto piccolo. Il condizionamento più alto è quello di **spa1**. Questa differenza di struttura spiega gran parte di ciò che vedremo: il costo di una iterazione dipende dal numero di entrate non nulle, mentre il numero di iterazioni dipende soprattutto dal condizionamento e dal metodo.

4.3 Tabelle complete dei risultati

Le quattro tabelle seguenti riportano, per ogni matrice e ogni tolleranza, il numero di iterazioni, l'errore relativo rispetto alla soluzione esatta, il residuo scalato raggiunto e il tempo. Sono i dati di `results.csv`. In tutte le prove i quattro metodi hanno raggiunto la convergenza: nessuno ha toccato il limite di 20000 iterazioni.

Tabella 3: Risultati su **spa1.mtx** ($n = 1000$, $\kappa \approx 2.0 \cdot 10^3$).

Metodo	tol	Iter.	Errore rel.	Residuo rel.	Tempo [s]
Jacobi	10^{-4}	115	$1.77 \cdot 10^{-3}$	$9.48 \cdot 10^{-5}$	0.013
Jacobi	10^{-6}	181	$1.80 \cdot 10^{-5}$	$9.62 \cdot 10^{-7}$	0.021
Jacobi	10^{-8}	247	$1.82 \cdot 10^{-7}$	$9.76 \cdot 10^{-9}$	0.028
Jacobi	10^{-10}	313	$1.85 \cdot 10^{-9}$	$9.91 \cdot 10^{-11}$	0.035
Gauss-Seidel	10^{-4}	9	$1.82 \cdot 10^{-2}$	$7.79 \cdot 10^{-5}$	0.002
Gauss-Seidel	10^{-6}	17	$1.30 \cdot 10^{-4}$	$5.58 \cdot 10^{-7}$	0.004
Gauss-Seidel	10^{-8}	24	$1.71 \cdot 10^{-6}$	$7.34 \cdot 10^{-9}$	0.006
Gauss-Seidel	10^{-10}	31	$2.25 \cdot 10^{-8}$	$9.65 \cdot 10^{-11}$	0.008
Gradiente	10^{-4}	143	$3.46 \cdot 10^{-2}$	$9.91 \cdot 10^{-5}$	0.016
Gradiente	10^{-6}	3577	$9.68 \cdot 10^{-4}$	$9.98 \cdot 10^{-7}$	0.407
Gradiente	10^{-8}	8233	$9.82 \cdot 10^{-6}$	$9.99 \cdot 10^{-9}$	0.930
Gradiente	10^{-10}	12919	$9.82 \cdot 10^{-8}$	$9.99 \cdot 10^{-11}$	1.463
Grad. coniugato	10^{-4}	49	$2.08 \cdot 10^{-2}$	$9.78 \cdot 10^{-5}$	0.006
Grad. coniugato	10^{-6}	134	$2.55 \cdot 10^{-5}$	$9.74 \cdot 10^{-7}$	0.015
Grad. coniugato	10^{-8}	177	$1.32 \cdot 10^{-7}$	$9.03 \cdot 10^{-9}$	0.020
Grad. coniugato	10^{-10}	200	$1.20 \cdot 10^{-9}$	$7.94 \cdot 10^{-11}$	0.023

Tabella 4: Risultati su `spa2.mtx` ($n = 3000$, $\kappa \approx 1.4 \cdot 10^3$).

Metodo	tol	Iter.	Errore rel.	Residuo rel.	Tempo [s]
Jacobi	10^{-4}	36	$1.77 \cdot 10^{-3}$	$9.54 \cdot 10^{-5}$	0.043
Jacobi	10^{-6}	57	$1.67 \cdot 10^{-5}$	$9.00 \cdot 10^{-7}$	0.067
Jacobi	10^{-8}	78	$1.57 \cdot 10^{-7}$	$8.49 \cdot 10^{-9}$	0.097
Jacobi	10^{-10}	99	$1.48 \cdot 10^{-9}$	$8.01 \cdot 10^{-11}$	0.119
Gauss-Seidel	10^{-4}	5	$2.60 \cdot 10^{-3}$	$4.14 \cdot 10^{-5}$	0.013
Gauss-Seidel	10^{-6}	8	$5.14 \cdot 10^{-5}$	$7.85 \cdot 10^{-7}$	0.020
Gauss-Seidel	10^{-8}	12	$2.79 \cdot 10^{-7}$	$4.27 \cdot 10^{-9}$	0.031
Gauss-Seidel	10^{-10}	15	$5.57 \cdot 10^{-9}$	$8.52 \cdot 10^{-11}$	0.037
Gradiente	10^{-4}	161	$1.81 \cdot 10^{-2}$	$9.90 \cdot 10^{-5}$	0.186
Gradiente	10^{-6}	1949	$6.69 \cdot 10^{-4}$	$9.99 \cdot 10^{-7}$	2.280
Gradiente	10^{-8}	5087	$6.87 \cdot 10^{-6}$	$9.98 \cdot 10^{-9}$	6.028
Gradiente	10^{-10}	8285	$6.94 \cdot 10^{-8}$	$9.99 \cdot 10^{-11}$	9.891
Grad. coniugato	10^{-4}	42	$9.82 \cdot 10^{-3}$	$9.91 \cdot 10^{-5}$	0.049
Grad. coniugato	10^{-6}	122	$1.20 \cdot 10^{-4}$	$9.09 \cdot 10^{-7}$	0.144
Grad. coniugato	10^{-8}	196	$5.59 \cdot 10^{-7}$	$9.60 \cdot 10^{-9}$	0.232
Grad. coniugato	10^{-10}	240	$5.32 \cdot 10^{-9}$	$9.82 \cdot 10^{-11}$	0.291

Tabella 5: Risultati su `vem1.mtx` ($n = 1681$, $\kappa \approx 3.2 \cdot 10^2$).

Metodo	tol	Iter.	Errore rel.	Residuo rel.	Tempo [s]
Jacobi	10^{-4}	1314	$3.54 \cdot 10^{-3}$	$9.99 \cdot 10^{-5}$	0.015
Jacobi	10^{-6}	2433	$3.54 \cdot 10^{-5}$	$9.99 \cdot 10^{-7}$	0.029
Jacobi	10^{-8}	3552	$3.54 \cdot 10^{-7}$	$9.99 \cdot 10^{-9}$	0.040
Jacobi	10^{-10}	4671	$3.54 \cdot 10^{-9}$	$9.99 \cdot 10^{-11}$	0.052
Gauss-Seidel	10^{-4}	659	$3.51 \cdot 10^{-3}$	$9.93 \cdot 10^{-5}$	0.018
Gauss-Seidel	10^{-6}	1218	$3.53 \cdot 10^{-5}$	$9.99 \cdot 10^{-7}$	0.032
Gauss-Seidel	10^{-8}	1778	$3.52 \cdot 10^{-7}$	$9.96 \cdot 10^{-9}$	0.048
Gauss-Seidel	10^{-10}	2338	$3.51 \cdot 10^{-9}$	$9.94 \cdot 10^{-11}$	0.063
Gradiente	10^{-4}	890	$2.70 \cdot 10^{-3}$	$9.93 \cdot 10^{-5}$	0.013
Gradiente	10^{-6}	1612	$2.71 \cdot 10^{-5}$	$9.97 \cdot 10^{-7}$	0.023
Gradiente	10^{-8}	2336	$2.70 \cdot 10^{-7}$	$9.90 \cdot 10^{-9}$	0.033
Gradiente	10^{-10}	3058	$2.71 \cdot 10^{-9}$	$9.97 \cdot 10^{-11}$	0.043
Grad. coniugato	10^{-4}	38	$4.08 \cdot 10^{-5}$	$7.11 \cdot 10^{-5}$	0.0006
Grad. coniugato	10^{-6}	45	$3.73 \cdot 10^{-7}$	$8.90 \cdot 10^{-7}$	0.0007
Grad. coniugato	10^{-8}	53	$2.83 \cdot 10^{-9}$	$7.80 \cdot 10^{-9}$	0.0008
Grad. coniugato	10^{-10}	59	$2.19 \cdot 10^{-11}$	$6.91 \cdot 10^{-11}$	0.0009

Tabella 6: Risultati su `vem2.mtx` ($n = 2601$, $\kappa \approx 5.1 \cdot 10^2$).

Metodo	tol	Iter.	Errore rel.	Residuo rel.	Tempo [s]
Jacobi	10^{-4}	1927	$4.97 \cdot 10^{-3}$	$9.99 \cdot 10^{-5}$	0.029
Jacobi	10^{-6}	3676	$4.97 \cdot 10^{-5}$	$9.99 \cdot 10^{-7}$	0.055
Jacobi	10^{-8}	5425	$4.97 \cdot 10^{-7}$	$9.99 \cdot 10^{-9}$	0.082
Jacobi	10^{-10}	7174	$4.96 \cdot 10^{-9}$	$9.98 \cdot 10^{-11}$	0.110
Gauss-Seidel	10^{-4}	965	$4.95 \cdot 10^{-3}$	$9.98 \cdot 10^{-5}$	0.036
Gauss-Seidel	10^{-6}	1840	$4.94 \cdot 10^{-5}$	$9.96 \cdot 10^{-7}$	0.069
Gauss-Seidel	10^{-8}	2714	$4.96 \cdot 10^{-7}$	$9.99 \cdot 10^{-9}$	0.104
Gauss-Seidel	10^{-10}	3589	$4.95 \cdot 10^{-9}$	$9.97 \cdot 10^{-11}$	0.134
Gradiente	10^{-4}	1308	$3.81 \cdot 10^{-3}$	$9.98 \cdot 10^{-5}$	0.024
Gradiente	10^{-6}	2438	$3.79 \cdot 10^{-5}$	$9.92 \cdot 10^{-7}$	0.045
Gradiente	10^{-8}	3566	$3.81 \cdot 10^{-7}$	$9.97 \cdot 10^{-9}$	0.065
Gradiente	10^{-10}	4696	$3.80 \cdot 10^{-9}$	$9.94 \cdot 10^{-11}$	0.084
Grad. coniugato	10^{-4}	47	$5.73 \cdot 10^{-5}$	$9.19 \cdot 10^{-5}$	0.0009
Grad. coniugato	10^{-6}	56	$4.74 \cdot 10^{-7}$	$8.54 \cdot 10^{-7}$	0.0011
Grad. coniugato	10^{-8}	66	$4.30 \cdot 10^{-9}$	$8.60 \cdot 10^{-9}$	0.0013
Grad. coniugato	10^{-10}	74	$2.25 \cdot 10^{-11}$	$5.90 \cdot 10^{-11}$	0.0013

Le tabelle mostrano due fatti generali. Primo, il residuo finale è sempre appena sotto la tolleranza richiesta: il criterio di arresto funziona come previsto. Secondo, l'errore relativo scala come la tolleranza. Quando `tol` scende di un fattore 100, anche l'errore scende di circa 100. Questo dice che errore e residuo sono proporzionali, e il fattore di proporzionalità dipende dalla matrice e dal metodo. Sul resto, cioè quanto costano in iterazioni e in tempo, i metodi si comportano in modo molto diverso, e lo analizziamo nei grafici seguenti.

4.4 Numero di iterazioni

Il grafico seguente mostra il numero di iterazioni in funzione della tolleranza, una riga per ogni matrice.




Figura 1: Numero di iterazioni al variare della tolleranza, per ciascun metodo e ciascuna matrice. Asse delle ascisse in scala logaritmica, con la tolleranza che cala da sinistra a destra.

Il gradiente coniugato richiede sempre pochissime iterazioni, da qualche decina a un paio di centinaia, e la sua linea resta quasi piatta in basso. Il gradiente semplice è il più lento sulle matrici **spa**, dove arriva a quasi 13000 iterazioni su **spa1**, perché il condizionamento alto lo fa procedere a zig-zag. Sulle matrici **vem** il gradiente è invece in linea con Jacobi e Gauss-

Seidel. Gauss–Seidel usa sempre meno iterazioni di Jacobi, perché riusa subito i valori appena aggiornati: circa la metà sulle matrici **vem**, fino a un decimo sulle **spa**. Si vede anche che per tutti i metodi il numero di iterazioni cresce in modo regolare al diminuire della tolleranza: passare da 10^{-4} a 10^{-10} aggiunge iterazioni, ma in modo lineare nel numero di cifre richieste.

4.5 Errore relativo

La figura seguente mostra l'errore relativo rispetto alla soluzione esatta.




Figura 2: Errore relativo $\|\mathbf{x} - \mathbf{x}^{(k)}\|/\|\mathbf{x}\|$ al variare della tolleranza. Entrambi gli assi in scala logaritmica.

Le rette scendono in modo regolare: l'errore è proporzionale alla tolleranza, come avevamo notato dalle tabelle. La pendenza è quasi la stessa per tutti, segno che la proporzionalità tra errore e residuo non cambia con la tolleranza. Cambia invece la posizione delle rette. Sulle matrici **vem** il gradiente coniugato sta nettamente più in basso degli altri tre: a parità di tolleranza

raggiunge un errore più piccolo. Sulle **spa** le quattro rette sono più vicine. Vale la pena notare che l'errore non è uguale alla tolleranza ma può essere più grande o più piccolo: il legame tra residuo ed errore passa per il condizionamento della matrice, come riprendiamo nel grafico di amplificazione.

4.6 Tempo di calcolo

La figura seguente mostra il tempo di calcolo.




Figura 3: Tempo di calcolo al variare della tolleranza. Asse delle ordinate in scala logaritmica.

Il tempo segue il numero di iterazioni moltiplicato per il costo di una iterazione. Sulle matrici *spa* il più veloce è Gauss-Seidel, perché converge in pochissime iterazioni; il gradiente coniugato è secondo e il gradiente semplice è di gran lunga il più lento, fino a quasi 10 secondi su *spa2*. Sulle matrici *vem* la situazione si ribalta: il gradiente coniugato è di gran lunga il più veloce, sotto il millesimo di secondo, mentre gli altri tre stanno vicini tra loro e molto più in alto. Il motivo

è che su **vem** gli altri metodi richiedono migliaia di iterazioni, mentre al gradiente coniugato ne basta qualche decina.

4.7 Storia di convergenza

La figura seguente mostra come scende il residuo scalato iterazione dopo iterazione, alla tolleranza più stretta 10^{-10} .




Figura 4: Andamento del residuo scalato $\|r_k\|/\|b\|$ in funzione dell'iterazione k , per $\text{tol} = 10^{-10}$. Entrambi gli assi in scala logaritmica. La riga tratteggiata è la tolleranza.

Le curve dicono come converge ogni metodo. Sulle matrici **spa** Gauss–Seidel scende per primo, in modo ripido; il gradiente semplice continua a scendere molto lentamente per migliaia di iterazioni, segno della convergenza lenta a zig-zag. Il gradiente coniugato ha un andamento irregolare ma scende molto più in fretta del gradiente, e nelle ultime iterazioni la discesa accelera. Sulle matrici **vem** il gradiente coniugato si stacca nettamente: dopo poche decine di iterazioni scende sotto la tolleranza in modo quasi verticale, mentre Jacobi, Gauss–Seidel e gradiente continuano a scendere piano per migliaia di iterazioni quasi sovrapposti.

4.8 Iterazioni e numero di condizionamento

Il grafico seguente mette le iterazioni in funzione del numero di condizionamento.




Figura 5: Iterazioni in funzione di $\kappa(A)$ a $\text{tol} = 10^{-8}$.

Le curve di Jacobi e Gauss–Seidel non sono monotone in $\kappa(A)$: ad esempio Gauss–Seidel richiede poche iterazioni sulle matrici **spa**, che pure hanno il condizionamento più alto. Il motivo è che il numero di condizionamento da solo non basta a prevedere le iterazioni di questi due metodi: conta anche la struttura della matrice e la distribuzione degli autovalori. I quattro punti, inoltre, vengono da due famiglie di matrici diverse, quindi il confronto va letto come tendenza, non come legge esatta.

4.9 Costo medio per iterazione

La figura seguente mostra il tempo medio di una singola iterazione, cioè il tempo totale diviso per il numero di iterazioni.




Figura 6: Tempo medio per iterazione a $\text{tol} = 10^{-8}$. Asse delle ordinate in scala logaritmica.

Questo grafico isola il costo di un passo dal numero di passi. Il costo per iterazione cresce con il numero di entrate non nulle: **spa2**, la matrice più grande e con più entrate, è la più costosa per tutti i metodi, mentre le **vem**, molto sparse, sono le meno costose. A parità di matrice i tre metodi che fanno un solo prodotto matrice-vettore, cioè Jacobi, gradiente e gradiente coniugato, hanno costo per iterazione simile. Gauss-Seidel è più costoso degli altri, soprattutto sulle matrici **vem**: la sostituzione in avanti è sequenziale e non sfrutta la vettorizzazione come il prodotto matrice-vettore. Quindi Gauss-Seidel conviene quando il taglio nelle iterazioni ripaga il maggior costo del singolo passo, cosa che succede sulle **spa** ma non sulle **vem**.

4.10 Amplificazione errore/residuo

La figura seguente mostra il rapporto tra errore relativo e residuo relativo, confrontato con il numero di condizionamento.




Figura 7: Rapporto fra errore relativo e residuo relativo a $\text{tol} = 10^{-8}$. La linea tratteggiata nera su ogni gruppo è $\text{cond}(A)$, limite superiore teorico del rapporto.

Il residuo piccolo non garantisce da solo un errore altrettanto piccolo: il legame tra i due passa per il condizionamento. Vale la stima $\text{errore relativo} \leq \kappa(A) \cdot \text{residuo relativo}$, e il grafico verifica che per ogni metodo il rapporto resta sotto la linea di $\text{cond}(A)$. Il limite è però pessimistico: i rapporti reali sono molto più bassi del condizionamento. Il gradiente semplice è quello che amplifica di più, vicino a 1000 sulle **spa**; il gradiente coniugato è quello che amplifica di meno e sulle matrici **vem** arriva sotto 1, cioè ottiene un errore addirittura più piccolo del proprio residuo. Questo spiega perché nel grafico dell'errore relativo il gradiente coniugato stava più in basso degli altri sulle **vem**.

4.11 Riepilogo

La figura seguente raccoglie tempo e iterazioni in due grafici a barre, per un confronto diretto a $\text{tol} = 10^{-8}$.




Figura 8: Confronto a barre del tempo (sopra) e delle iterazioni (sotto) a $\text{tol} = 10^{-8}$. Assi delle ordinate in scala logaritmica.

I due grafici riassumono tutto. In iterazioni il gradiente coniugato è quasi sempre il migliore, seguito da Gauss-Seidel; il gradiente semplice è il peggiore sulle *spa*. In tempo il quadro dipende dalla matrice: Gauss-Seidel è il più rapido sulle *spa* perché poche iterazioni ripagano il passo costoso, mentre il gradiente coniugato domina sulle *vem* grazie al numero piccolo di iterazioni. Il gradiente semplice resta la scelta peggiore quando la matrice è mal condizionata.

5 Conclusioni

Abbiamo implementato i quattro metodi iterativi richiesti all'interno di una libreria dotata di una struttura comune, in cui ogni algoritmo definisce unicamente la propria regola di aggiornamento. I test eseguiti su quattro matrici reali, a diverse tolleranze, hanno prodotto risultati del tutto coerenti con le aspettative teoriche. Il criterio di arresto basato sul residuo scalato si è dimostrato stabile ed efficace per ogni caso analizzato: in tutte le prove il residuo finale si posiziona appena al di sotto della tolleranza imposta, nessun metodo ha mai raggiunto il limite massimo di iterazioni consentite e l'errore relativo è scalato in proporzionalità diretta con la tolleranza.

Confrontando i metodi sul piano pratico, emerge chiaramente come il gradiente coniugato rappresenti la scelta più robusta ed efficiente nella maggior parte delle situazioni. Il suo andamento iterativo segue la crescita della radice quadrata del numero di condizionamento, annullando il problema della discesa a zig-zag tipica del gradiente semplice. Questo vantaggio gli

permette di convergere in pochissimi passi e di risultare il metodo in assoluto più rapido per la risoluzione di sistemi lineari basati su matrici molto sparse, come quelle relative alla famiglia *vem*.

Il metodo di Gauss-Seidel, pur avendo un costo computazionale per iterazione maggiore a causa della natura sequenziale della sostituzione in avanti, si difende in modo eccellente grazie al minor numero complessivo di passi necessari alla convergenza, ottenuto impiegando immediatamente i valori calcolati all'interno dello stesso ciclo. Nelle matrici a media densità, come quelle della famiglia *spa*, questo risparmio di iterazioni compensa il peso del singolo passo, rendendo Gauss-Seidel l'algoritmo più veloce in assoluto per questa particolare tipologia di dati.

I metodi di Jacobi e del gradiente semplice, invece, non risultano mai la scelta ottimale nei casi di test esaminati. Il metodo di Jacobi soffre di un numero troppo elevato di iterazioni necessarie alla convergenza rispetto all'analogo Gauss-Seidel, mentre il gradiente semplice paga un costo altissimo al crescere del numero di condizionamento della matrice. Restano tuttavia essenziali come base matematica e come punti di riferimento teorico.

In sintesi, l'analisi sperimentale conferma l'efficacia dell'approccio strutturato a oggetti e identifica nel gradiente coniugato il metodo di riferimento per la risoluzione pratica di problemi simmetrici e definiti positivi di grandi dimensioni, lasciando a Gauss-Seidel un ruolo di primaria importanza per i soli casi di sistemi lineari caratterizzati da matrici più dense.

6 Documentazione

Il codice è documentato in modo sistematico: ogni modulo ha una *docstring* di intestazione che ne descrive lo scopo, e ogni funzione o classe pubblica ha una *docstring* che ne specifica comportamento, argomenti, valore di ritorno ed eccezioni. Le firme usano le annotazioni di tipo (*type hints*). Di seguito riportiamo la documentazione per modulo. Per le funzioni di servizio interne, marcate con l'underscore iniziale, diamo solo una riga di descrizione.

6.1 Modulo `solvers.py`

È la libreria vera e propria. Contiene lo scheletro comune di iterazione, le quattro sottoclassi dei metodi e alcune funzioni di servizio.

`class IterativeSolver`. Classe base astratta con lo scheletro comune ai quattro metodi. Le sottoclassi forniscono solo la propria regola di aggiornamento, tramite il metodo astratto `_make_iteration`.

`IterativeSolver.solve(A, b, tol, max_iter=None, record_history=False)`. Risolve $Ax = b$ partendo da $x^{(0)} = \mathbf{0}$. Itera finché il residuo scalato scende sotto `tol` oppure finché si superano `max_iter` iterazioni; in questo secondo caso la soluzione è restituita con `converged=False`.

- *Input*: `A` (matrice sparsa CSR, $n \times n$), `b` (array, shape $(n,)$), `tol` (float), `max_iter` (int, default 20000), `record_history` (bool: se vero salva la storia del residuo per i grafici di convergenza).
- *Output*: `SolverResult`.
- *Eccezioni*: `ValueError` se `A` non è quadrata o ha un elemento diagonale nullo.

`class SolverResult`. *Dataclass* che raccoglie il risultato di una risoluzione: nome del metodo, soluzione `x`, numero di iterazioni, tempo `elapsed`, residuo scalato raggiunto, flag `converged` ed eventuale `history` del residuo.

`class Jacobi, GaussSeidel, Gradient, ConjugateGradient`. Le quattro sottoclassi concrete di `IterativeSolver`. Ognuna implementa solo la propria iterazione, cioè la regola di aggiornamento descritta in precedenza, ed eredita il metodo `solve`.

`_gauss_seidel_sweep(indptr, indices, data, diag, b, x)`. Una iterazione (*sweep*) di Gauss–Seidel per sostituzione in avanti, che aggiorna $\mathbf{x}$ *in place*. È sequenziale e quindi compilata con `numba` per renderla veloce restando codice nostro. Lavora direttamente sugli array CSR della matrice.

`warmup()`. Forza la compilazione JIT di `numba` eseguendo i metodi su un problema 3×3 . Va chiamata prima delle misure di tempo, così la prima esecuzione di Gauss–Seidel non paga il costo di compilazione e i tempi non risultano falsati.

`SOLVERS`. Tupla con le istanze dei quattro metodi, nell’ordine richiesto dalla traccia.

6.2 Modulo `run_assignment.py`

È l’eseguibile da riga di comando che applica i quattro metodi alle matrici e salva i risultati.

`main()`. Legge le matrici, calcola il numero di condizionamento $\kappa(A)$ tramite `scipy.sparse.linalg.eigsh`, costruisce la soluzione esatta $\mathbf{x} = \mathbf{1}$ e il termine noto $\mathbf{b} = A\mathbf{x}$, applica i quattro metodi a ogni tolleranza, stampa a schermo errore relativo, iterazioni e tempo, scrive il tutto su `results.csv` e, se richiesto, genera i grafici di base.

`parse_args()`. Legge gli argomenti da riga di comando.

- `-matrix`: matrice `.mtx` da usare, ripetibile; se assente usa tutti i file in `dati/`.
- `-tol`: tolleranza, ripetibile; default $10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$.
- `-method`: metodo da usare fra `jacobi`, `gauss-seidel`, `gradient`, `conjugate-gradient`; ripetibile, default tutti.
- `-max-iter`: numero massimo di iterazioni, default 20000.
- `-output`: cartella di output, default `results`.
- `-no-plots`: non genera i grafici.

6.3 Modulo `plots.py`

Genera i grafici a partire dai file CSV. Riesegue i solutori solo per la storia di convergenza, che richiede di registrare il residuo a ogni iterazione.

`create_plots(rows, output_dir)`. Genera i tre grafici di base (errore, iterazioni e tempo in funzione della tolleranza). *Output*: lista dei percorsi dei file PNG scritti.

`compute_histories(tol, max_iter)`. Riesegue i solutori con `record_history=True` e restituisce, per ogni matrice e metodo, la storia del residuo scalato.

`plot_convergence`, `plot_error_vs_residual`, `plot_cost_per_iter`, `plot_summary_bars`. Le funzioni che disegnano i grafici di approfondimento dei risultati, uno per ciascuna figura.

6.4 Modulo `test_assignment.py`

Test rapidi su matrici piccole: controllano la lettura del formato MatrixMarket, la convergenza dei quattro metodi su una matrice tridiagonale SPD e il fatto che il gradiente coniugato converga in al più n iterazioni su un sistema piccolo.

6.5 Esecuzione

Dopo aver installato le dipendenze con `pip install -r requirements.txt`, l’esecuzione completa è

```
python run_assignment.py
```

che usa tutte le matrici in `dati/` e le quattro tolleranze richieste. Si possono scegliere matrice, tolleranza e metodo con gli argomenti descritti sopra:

```
python run_assignment.py --matrix dati/vem1.mtx --tol 1e-8
python run_assignment.py --method conjugate-gradient --no-plots
```

I grafici di approfondimento si generano con `python plots.py` dopo aver prodotto `results.csv`; i test con `python test_assignment.py`.

7 Codice

Per completezza riportiamo il codice sorgente dei file principali.

7.1 solvers.py

```
1 from __future__ import annotations
2
3 from abc import ABC, abstractmethod
4 from dataclasses import dataclass
5 from time import perf_counter
6 from typing import Any
7
8 import numpy as np
9 from numba import njit
10
11
12 # -----
13 # Risultato di una risoluzione.
14 # -----
15 @dataclass
16 class SolverResult:
17     method: str # nome del metodo
18     x: np.ndarray # soluzione approssimata  $x^{(k)}$ 
19     iterations: int # numero di iterazioni eseguite
20     elapsed: float # tempo di calcolo in secondi
21     residual_relative: float #  $\|b - Ax\|/\|b\|$  raggiunto
22     converged: bool # True se il criterio di arresto e' stato soddisfatto
23     history: list[float] | None = None # storia del residuo scalato (solo se richiesta)
24
25
26 # -----
27 # Iterazione astratta + classe base con lo scheletro comune.
28 # -----
29 class _Iteration(ABC):
30     """Stato interno di un metodo iterativo per un singolo problema.
31
32     Mantiene (e aggiorna in place) il vettore soluzione ' $x$ ' e quanto serve per
33     calcolare il residuo ed eseguire il passo di aggiornamento.
34     """
35
36     @abstractmethod
37     def residual_norm(self) -> float:
38         """Norma euclidea del residuo corrente  $\|b - Ax^{(k)}\|$ ."""
39
40     @abstractmethod
41     def step(self) -> None:
42         """Aggiorna lo stato:  $x^{(k)} \rightarrow x^{(k+1)}$ ."""
43
44
45 class IterativeSolver(ABC):
```

```

46     """Classe base: implementa lo scheletro comune a tutti i metodi."""
47
48     name: str = "iterative"
49     key: str = "iterative" # identificativo per la CLI
50     DEFAULT_MAX_ITER: int = 20000
51
52     @abstractmethod
53     def _make_iteration(self, A: Any, b: np.ndarray, x: np.ndarray) -> _Iteration:
54         """Costruisce l'oggetto iterazione specifico del metodo."""
55
56     def solve(self, A: Any, b: np.ndarray, tol: float,
57               max_iter: int | None = None,
58               record_history: bool = False) -> SolverResult:
59         """Risolve  $Ax = b$  partendo da  $x^{(0)} = 0$ .
60
61         Si arresta quando il residuo scalato scende sotto 'tol' oppure quando
62         si superano 'max_iter' iterazioni (in tal caso converged=False).
63
64         Se 'record_history=True' salva in 'SolverResult.history' il residuo
65         scalato a ogni iterazione (partendo dal valore iniziale = 1). Il valore
66         e' gia' calcolato dal ciclo, quindi non comporta matvec aggiuntivi; va
67         comunque usato SOLO per i grafici di convergenza, NON per le misure di
68         tempo (l'append alla lista introduce un piccolo overhead di Python).
69         """
70         _validate_for_iteration(A)
71         if max_iter is None:
72             max_iter = self.DEFAULT_MAX_ITER
73
74         b = np.asarray(b, dtype=float)
75         x = np.zeros_like(b, dtype=float) # vettore iniziale nullo
76         b_norm = _safe_norm(b)
77
78         start_time = perf_counter()
79         it = self._make_iteration(A, b, x)
80         iterations = 0
81         residual_relative = it.residual_norm() / b_norm # all'inizio vale 1
82         history = [residual_relative] if record_history else None
83         while residual_relative >= tol and iterations < max_iter:
84             it.step()
85             iterations += 1
86             residual_relative = it.residual_norm() / b_norm
87             if history is not None:
88                 history.append(residual_relative)
89         elapsed = perf_counter() - start_time
90
91         return SolverResult(
92             method=self.name,
93             x=x.copy(),
94             iterations=iterations,
95             elapsed=elapsed,
96             residual_relative=residual_relative,
97             converged=residual_relative < tol,
98             history=history,
99         )
100
101
102     # -----
103     # 1) Metodo di Jacobi.  $P = \text{diag}(A)$ ,  $x \leftarrow x + P^{-1} r$ ,  $r = b - Ax$ .
104     # -----
105     class _JacobiIteration(_Iteration):
106         def __init__(self, A, b, x):
107             self.A = A
108             self.b = b

```

```

109     self.x = x
110     self.inv_diag = 1.0 / np.asarray(A.diagonal(), dtype=float) #  $P^{-1}$ 
111     self.residual = b - A @ x # residuo iniziale (= b)
112
113     def residual_norm(self):
114         return float(np.linalg.norm(self.residual))
115
116     def step(self):
117         #  $x^{(k+1)} = x^{(k)} + P^{-1} r^{(k)}$ 
118         self.x += self.inv_diag * self.residual
119         self.residual = self.b - self.A @ self.x
120
121
122 class Jacobi(IterativeSolver):
123     name = "Jacobi"
124     key = "jacobi"
125
126     def _make_iteration(self, A, b, x):
127         return _JacobiIteration(A, b, x)
128
129
130 # -----
131 # 2) Metodo di Gauss-Seidel.  $P$  = parte triangolare inferiore di  $A$ .
132 # sweep in place (= sostituzione in avanti), poi  $r = b - A x$ .
133 # -----
134 class _GaussSeidelIteration(_Iteration):
135     def __init__(self, A, b, x):
136         self.A = A
137         self.b = b
138         self.x = x
139         self.diag = np.asarray(A.diagonal(), dtype=float)
140         self.indptr = A.indptr
141         self.indices = A.indices
142         self.data = np.asarray(A.data, dtype=float)
143         self.residual = b - A @ x
144
145     def residual_norm(self):
146         return float(np.linalg.norm(self.residual))
147
148     def step(self):
149         _gauss_seidel_sweep(self.indptr, self.indices, self.data,
150                             self.diag, self.b, self.x)
151         self.residual = self.b - self.A @ self.x
152
153
154 class GaussSeidel(IterativeSolver):
155     name = "Gauss-Seidel"
156     key = "gauss-seidel"
157
158     def _make_iteration(self, A, b, x):
159         return _GaussSeidelIteration(A, b, x)
160
161
162 # -----
163 # 3) Metodo del Gradiente (steepest descent).
164 #  $\alpha = (r \cdot r) / (r \cdot A r)$  ;  $x \leftarrow x + \alpha r$  ;  $r \leftarrow r - \alpha A r$ .
165 # -----
166 class _GradientIteration(_Iteration):
167     def __init__(self, A, b, x):
168         self.A = A
169         self.b = b
170         self.x = x
171         self.residual = b - A @ x # = -grad(phi) in x

```



```

172
173 def residual_norm(self):
174     return float(np.linalg.norm(self.residual))
175
176 def step(self):
177     Ar = self.A @ self.residual
178     denom = float(np.dot(self.residual, Ar))
179     alpha = float(np.dot(self.residual, self.residual)) / denom
180     self.x += alpha * self.residual
181     #  $r^{(k+1)} = b - A x^{(k+1)} = r^{(k)} - \alpha A r^{(k)}$ : niente matvec extra
182     self.residual = self.residual - alpha * Ar
183
184
185 class Gradient(IterativeSolver):
186     name = "Gradiente"
187     key = "gradient"
188
189     def _make_iteration(self, A, b, x):
190         return _GradientIteration(A, b, x)
191
192
193 # -----
194 # 4) Metodo del Gradiente coniugato.
195 # Direzioni A-coniugate: niente "zig-zag", convergenza in  $\leq n$  passi.
196 # -----
197 class _ConjugateGradientIteration(_Iteration):
198     def __init__(self, A, b, x):
199         self.A = A
200         self.b = b
201         self.x = x
202         self.residual = b - A @ x # residuo iniziale (= b)
203         self.direction = self.residual.copy() #  $d^{(0)} = r^{(0)}$ 
204         self.residual_norm_sq = float(np.dot(self.residual, self.residual))
205
206     def residual_norm(self):
207         return float(np.sqrt(self.residual_norm_sq))
208
209     def step(self):
210         Ad = self.A @ self.direction
211         denom = float(np.dot(self.direction, Ad))
212         alpha = self.residual_norm_sq / denom
213         self.x += alpha * self.direction
214         self.residual = self.residual - alpha * Ad
215         new_norm_sq = float(np.dot(self.residual, self.residual))
216         beta = new_norm_sq / self.residual_norm_sq
217         self.direction = self.residual + beta * self.direction
218         self.residual_norm_sq = new_norm_sq
219
220
221 class ConjugateGradient(IterativeSolver):
222     name = "Gradiente coniugato"
223     key = "conjugate-gradient"
224
225     def _make_iteration(self, A, b, x):
226         return _ConjugateGradientIteration(A, b, x)
227
228
229 # Istanze dei quattro metodi, nell'ordine richiesto dalla consegna.
230 SOLVERS: tuple[IterativeSolver, ...] = (
231     Jacobi(),
232     GaussSeidel(),
233     Gradient(),
234     ConjugateGradient(),

```

```

235 )
236
237
238 # -----
239 # Routine compilata (numba) e funzioni di servizio condivise.
240 # -----
241 @njit(cache=True)
242 def _gauss_seidel_sweep(indptr, indices, data, diag, b, x):
243     """Una iterazione (sweep) di Gauss-Seidel, aggiornando x in place.
244
245     Equivale a risolvere  $(D + L)y = r$  per sostituzione in avanti: ogni  $x[i]$  usa
246     i valori già aggiornati  $x[0..i-1]$  e quelli vecchi  $x[i+1..n-1]$ . E'
247     un'operazione sequenziale ( $x[i]$  dipende dai precedenti) e quindi non
248     vettorizzabile: la compiliamo con numba per renderla veloce restando codice
249     nostro (non usiamo nessun solutore di libreria).
250     """
251     n = x.shape[0]
252     for i in range(n):
253         sigma = 0.0
254         for k in range(indptr[i], indptr[i + 1]):
255             j = indices[k]
256             if j != i:
257                 sigma += data[k] * x[j]
258             x[i] = (b[i] - sigma) / diag[i]
259
260
261 def warmup() -> None:
262     """Forza la compilazione JIT (numba) su un problemino 3x3.
263
264     Va chiamata PRIMA delle misure di tempo: altrimenti la prima esecuzione di
265     Gauss-Seidel paga il costo (una tantum) di compilazione della sweep,
266     falsando il tempo riportato.
267     """
268     from scipy.sparse import csr_matrix
269
270     A = csr_matrix(np.array([[4.0, 1.0, 0.0],
271                             [1.0, 4.0, 1.0],
272                             [0.0, 1.0, 4.0]]))
273     b = A @ np.ones(3)
274     for solver in SOLVERS:
275         solver.solve(A, b, 1e-12, 100)
276
277
278 def _validate_for_iteration(A: Any) -> None:
279     if A.shape[0] != A.shape[1]:
280         raise ValueError("La matrice deve essere quadrata")
281     diag = np.asarray(A.diagonal(), dtype=float)
282     if np.any(diag == 0):
283         raise ValueError("La matrice ha almeno un elemento diagonale nullo")
284
285
286 def _safe_norm(x: np.ndarray) -> float:
287     norm = float(np.linalg.norm(x))
288     if norm == 0:
289         return 1.0
290     return norm

```

7.2 run_assignment.py

```

1  """Command line runner for the first MCS assignment."""
2

```

```

3 from __future__ import annotations
4
5 import argparse
6 import csv
7 from pathlib import Path
8
9 import numpy as np
10 from scipy.io import mmread
11 from scipy.sparse.linalg import eigsh
12
13 from plots import create_plots
14 from solvers import SOLVERS, warmup
15
16
17 DEFAULT_TOLS = (1e-4, 1e-6, 1e-8, 1e-10)
18 DEFAULT_MAX_ITER = 20000
19 METHOD_NAMES = tuple(solver.key for solver in SOLVERS)
20
21
22 def main() -> None:
23     args = parse_args()
24     base_dir = Path(__file__).resolve().parent
25     output_dir = args.output
26     if not output_dir.is_absolute():
27         output_dir = base_dir / output_dir
28     output_dir.mkdir(parents=True, exist_ok=True)
29
30     matrix_paths = _resolve_matrices(args, base_dir)
31     tolerances = args.tol if args.tol else list(DEFAULT_TOLS)
32     solvers = _select_solvers(args.method)
33
34     warmup() # compilazione JIT (numba) prima delle misure di tempo
35
36     rows: list[dict[str, str]] = []
37     for matrix_path in matrix_paths:
38         print(f"\nMatrice: {matrix_path}")
39         A = mmread(matrix_path).tocsr().astype(float)
40         x_exact = np.ones(A.shape[0], dtype=float)
41         b = A @ x_exact
42
43         lam_max = float(eigsh(A, k=1, which="LM", return_eigenvectors=False)[0])
44         lam_min = float(eigsh(A, k=1, sigma=0.0, which="LM", return_eigenvectors=False)[0])
45         cond = lam_max / lam_min
46
47         for tol in tolerances:
48             print(f" tol = {tol:g}")
49             for solver in solvers:
50                 result = solver.solve(A, b, tol, args.max_iter)
51                 relative_error = np.linalg.norm(x_exact - result.x) / np.linalg.norm(x_exact)
52                 row = {
53                     "matrix": matrix_path.name,
54                     "n": str(A.shape[0]),
55                     "nnz": str(A.nnz),
56                     "lambda_min": f"{lam_min:.16e}",
57                     "lambda_max": f"{lam_max:.16e}",
58                     "cond": f"{cond:.16e}",
59                     "tol": f"{tol:.0e}",
60                     "method": result.method,
61                     "relative_error": f"{relative_error:.16e}",
62                     "residual_relative": f"{result.residual_relative:.16e}",
63                     "iterations": str(result.iterations),
64                     "elapsed_seconds": f"{result.elapsed:.6f}",
65                     "converged": str(result.converged),

```

```

66         }
67         rows.append(row)
68         print(
69             " "
70             f"{result.method:20s} "
71             f"it={result.iterations:6d} "
72             f"err={relative_error:.3e} "
73             f"res={result.residual_relative:.3e} "
74             f"time={result.elapsed:.3f}s "
75             f"conv={result.converged}"
76         )
77
78     csv_path = output_dir / "results.csv"
79     _write_csv(rows, csv_path)
80     print(f"\nCSV scritto in: {csv_path}")
81
82     if args.plots:
83         plot_paths = create_plots(rows, output_dir)
84         print(f"Grafici scritti in: {output_dir / 'plots'}")
85         for plot_path in plot_paths:
86             print(f" - {plot_path.name}")
87
88
89 def parse_args() -> argparse.Namespace:
90     parser = argparse.ArgumentParser(description="Mini libreria per sistemi lineari SPD")
91     parser.add_argument(
92         "--matrix",
93         action="append",
94         type=Path,
95         help="Matrice .mtx da usare. Ripetibile. Se assente usa tutti i file .mtx in dati.",
96     )
97     parser.add_argument(
98         "--tol",
99         action="append",
100        type=float,
101        help="Tolleranza da usare. Ripetibile. Se assente usa 1e-4, 1e-6, 1e-8, 1e-10.",
102    )
103    parser.add_argument(
104        "--max-iter",
105        type=int,
106        default=DEFAULT_MAX_ITER,
107        help="Numero massimo di iterazioni, default 20000.",
108    )
109    parser.add_argument(
110        "--method",
111        action="append",
112        choices=METHOD_NAMES,
113        help=(
114            "Metodo da usare. Ripetibile. Se assente usa tutti i metodi. "
115            f"Valori: {' ', ' '.join(METHOD_NAMES)}."
116        ),
117    )
118    parser.add_argument(
119        "--output",
120        type=Path,
121        default=Path("results"),
122        help="Cartella di output, default assignment 1/results.",
123    )
124    parser.add_argument(
125        "--no-plots",
126        dest="plots",
127        action="store_false",
128        help="Non generare grafici.",

```

```

129     )
130     parser.set_defaults(plots=True)
131     return parser.parse_args()
132
133
134 def _resolve_matrices(args: argparse.Namespace, base_dir: Path) -> list[Path]:
135     if args.matrix:
136         paths = args.matrix
137     else:
138         data_dir = base_dir / "dati"
139         paths = sorted(data_dir.glob("*.mtx"))
140         if not paths:
141             raise FileNotFoundError(f"Nessuna matrice .mtx trovata in: {data_dir}")
142
143     resolved = []
144     for path in paths:
145         if not path.is_absolute():
146             path = base_dir / path
147         if not path.exists():
148             raise FileNotFoundError(f"Matrice non trovata: {path}")
149         resolved.append(path)
150     return resolved
151
152
153 def _select_solvers(methods: list[str] | None):
154     if not methods:
155         return SOLVERS
156
157     selected = set(methods)
158     return tuple(solver for solver in SOLVERS if solver.key in selected)
159
160
161 def _write_csv(rows: list[dict[str, str]], csv_path: Path) -> None:
162     fieldnames = [
163         "matrix",
164         "n",
165         "nnz",
166         "lambda_min",
167         "lambda_max",
168         "cond",
169         "tol",
170         "method",
171         "relative_error",
172         "residual_relative",
173         "iterations",
174         "elapsed_seconds",
175         "converged",
176     ]
177     with csv_path.open("w", encoding="utf-8", newline="") as file:
178         writer = csv.DictWriter(file, fieldnames=fieldnames)
179         writer.writeheader()
180         writer.writerows(rows)
181
182
183 if __name__ == "__main__":
184     main()

```

7.3 plots.py

```

1 from __future__ import annotations
2

```

```

3 import argparse
4 import csv
5 from collections import defaultdict
6 from pathlib import Path
7
8 import numpy as np
9 from scipy.io import mmread
10 from scipy.sparse import csr_matrix
11
12 from solvers import SOLVERS, warmup
13
14 BASE_DIR = Path(__file__).resolve().parent
15 DATA_DIR = BASE_DIR / "dati"
16
17 # Ordine e colori dei metodi, coerenti in tutti i grafici di approfondimento.
18 METHOD_ORDER = [solver.name for solver in SOLVERS]
19 METHOD_COLORS = {
20     "Jacobi": "tab:blue",
21     "Gauss-Seidel": "tab:orange",
22     "Gradiente": "tab:green",
23     "Gradiente coniugato": "tab:red",
24 }
25
26
27 # -----
28 # Funzioni di servizio condivise.
29 # -----
30 def _save(fig, path: Path) -> None:
31     """Layout, salvataggio a 200 dpi e chiusura della figura."""
32     import matplotlib.pyplot as plt
33
34     fig.tight_layout()
35     fig.savefig(path, dpi=200)
36     plt.close(fig)
37
38
39 def load_rows(csv_path: Path) -> list[dict[str, str]]:
40     if not csv_path.exists():
41         raise FileNotFoundError(
42             f"Risultati non trovati: {csv_path}. Esegui prima 'python run_assignment.py'."
43         )
44     with csv_path.open(encoding="utf-8", newline="") as file:
45         return list(csv.DictReader(file))
46
47
48
49 def _closest_tol(rows: list[dict[str, str]], target: float) -> str:
50     """Etichetta di tolleranza presente nel CSV piu' vicina a 'target'."""
51     tols = sorted({row["tol"] for row in rows}, key=float)
52     return min(tols, key=lambda t: abs(np.log10(float(t)) - np.log10(target)))
53
54
55 def _methods_present(rows: list[dict[str, str]]) -> list[str]:
56     present = {row["method"] for row in rows}
57     return [m for m in METHOD_ORDER if m in present]
58
59
60 def _grouped_bars(ax, groups, series, value_fn) -> None:
61     """Disegna barre raggruppate: un gruppo per 'groups', una barra per
62     'series'. 'value_fn(group, serie)' ritorna l'altezza (o None)."""
63     n_series = max(len(series), 1)
64     width = 0.8 / n_series
65     x = np.arange(len(groups))

```

```

66     for j, serie in enumerate(series):
67         offset = (j - (n_series - 1) / 2) * width
68         heights = [value_fn(group, serie) or np.nan for group in groups]
69         ax.bar(x + offset, heights, width=width, label=serie,
70               color=METHOD_COLORS.get(serie))
71
72
73 # -----
74 # Grafici fondamentali: metrica vs tolleranza (richiamati da run_assignment.py).
75 # -----
76 def create_plots(rows: list[dict[str, str]], output_dir: str | Path) -> list[Path]:
77     output_dir = Path(output_dir)
78     plots_dir = output_dir / "plots"
79     plots_dir.mkdir(parents=True, exist_ok=True)
80
81     paths = [
82         plots_dir / "relative_error.png",
83         plots_dir / "iterations.png",
84         plots_dir / "time.png",
85     ]
86     _plot_metric(rows, "relative_error", "Errore relativo", paths[0], log_y=True)
87     _plot_metric(rows, "iterations", "Iterazioni", paths[1], log_y=False)
88     _plot_metric(rows, "elapsed_seconds", "Tempo [s]", paths[2], log_y=True)
89     return paths
90
91
92 def _plot_metric(
93     rows: list[dict[str, str]],
94     metric: str,
95     ylabel: str,
96     path: Path,
97     log_y: bool,
98 ) -> None:
99     import matplotlib.pyplot as plt
100
101     grouped = defaultdict(list)
102     for row in rows:
103         grouped[(row["matrix"], row["method"])].append(row)
104
105     matrices = sorted({row["matrix"] for row in rows})
106     fig, axes = plt.subplots(len(matrices), 1, figsize=(9, 3.2 * len(matrices)), squeeze=
107                             False)
108
109     for ax, matrix_name in zip(axes[:, 0], matrices):
110         for (current_matrix, method), values in grouped.items():
111             if current_matrix != matrix_name:
112                 continue
113             values = sorted(values, key=lambda item: float(item["tol"]))
114             xs = [float(item["tol"]) for item in values]
115             ys = [float(item[metric]) for item in values]
116             ax.plot(xs, ys, marker="o", label=method)
117
118             ax.set_title(matrix_name)
119             ax.set_xlabel("Tolleranza")
120             ax.set_ylabel(ylabel)
121             ax.set_xscale("log")
122             ax.invert_xaxis()
123             if log_y:
124                 ax.set_yscale("log")
125             ax.grid(True, which="both", alpha=0.3)
126             ax.legend()
127
128     _save(fig, path)

```

```

128
129
130 # -----
131 # A) Storia di convergenza.
132 # -----
133 def compute_histories(tol: float, max_iter: int) -> dict[str, dict[str, list[float]]]:
134     """Riesegue i solutori registrando la storia del residuo scalato.
135
136     Ritorna histories[matrice][metodo] = [r0, r1, ...] (r0 = 1).
137     """
138     warmup()
139     paths = sorted(DATA_DIR.glob("*.mtx"))
140     histories: dict[str, dict[str, list[float]]] = {}
141     for path in paths:
142         A = csr_matrix(mread(path), dtype=float)
143         # .shape e' tipato Optional negli stub di scipy: a runtime e' sempre una
144         # tupla (n, n), quindi il pedice e' sicuro.
145         x_exact = np.ones(A.shape[0], dtype=float) # type: ignore[reportOptionalSubscript]
146         b = A @ x_exact
147         per_method: dict[str, list[float]] = {}
148         for solver in SOLVERS:
149             result = solver.solve(A, b, tol, max_iter, record_history=True)
150             per_method[solver.name] = result.history or []
151         histories[path.name] = per_method
152         print(f" storia calcolata: {path.name}")
153     return histories
154
155
156 def plot_convergence(histories: dict[str, dict[str, list[float]]], tol: float,
157                     path: Path) -> None:
158     import matplotlib.pyplot as plt
159
160     matrices = sorted(histories)
161     fig, axes = plt.subplots(len(matrices), 1, figsize=(9, 3.2 * len(matrices)),
162                             squeeze=False)
163     for ax, matrix_name in zip(axes[:, 0], matrices):
164         for method in METHOD_ORDER:
165             history = histories[matrix_name].get(method)
166             if not history or len(history) < 2:
167                 continue
168             # Saltiamo il punto iniziale (r0 = 1, k = 0) perche' l'asse x e' in
169             # scala logaritmica: cosi' tutti i metodi sono visibili anche quando
170             # il numero di iterazioni varia di ordini di grandezza (es. CG ~10^2
171             # vs Gradiente ~10^4 sulle matrici spa).
172             tail = history[1:]
173             ax.plot(range(1, len(tail) + 1), tail, label=method,
174                     color=METHOD_COLORS.get(method))
175             ax.axhline(tol, color="gray", linestyle="--", linewidth=1,
176                       label=f"tol = {tol:g}")
177             ax.set_title(matrix_name)
178             ax.set_xlabel("Iterazione k")
179             ax.set_ylabel(r"$\|r_k\| / \|b\|$")
180             ax.set_xscale("log")
181             ax.set_yscale("log")
182             ax.grid(True, which="both", alpha=0.3)
183             ax.legend()
184         _save(fig, path)
185
186
187 # -----
188 # B) Iterazioni vs cond(A).
189 # -----
190 def plot_iter_vs_cond(rows: list[dict[str, str]], tol_label: str, path: Path) -> None:

```



```

191 import matplotlib.pyplot as plt
192
193 selected = [row for row in rows if row["tol"] == tol_label]
194 fig, ax = plt.subplots(figsize=(9, 6))
195
196 for method in _methods_present(selected):
197     points = [(float(row["cond"]), int(row["iterations"]))
198               for row in selected
199               if row["method"] == method and "cond" in row]
200     points.sort()
201     if not points:
202         continue
203     conds = [p[0] for p in points]
204     iters = [p[1] for p in points]
205     ax.plot(conds, iters, marker="o", label=method,
206             color=METHOD_COLORS.get(method))
207
208 ax.set_title(f"Iterazioni vs numero di condizionamento (tol = {tol_label})")
209 ax.set_xlabel(r"$\kappa(A) = \lambda_{\max} / \lambda_{\min}$")
210 ax.set_ylabel("Iterazioni")
211 ax.set_xscale("log")
212 ax.set_yscale("log")
213 ax.grid(True, which="both", alpha=0.3)
214 ax.legend()
215 _save(fig, path)
216
217
218 # -----
219 # C) Amplificazione errore/residuo.
220 # -----
221 def plot_error_vs_residual(rows: list[dict[str, str]], tol_label: str, path: Path) -> None:
222     import matplotlib.pyplot as plt
223
224     selected = [row for row in rows if row["tol"] == tol_label]
225     matrices = sorted({row["matrix"] for row in selected})
226     methods = _methods_present(selected)
227
228     ratios = defaultdict(dict) # ratios[matrix][method] = err/res
229     for row in selected:
230         res = float(row["residual_relative"])
231         if res > 0:
232             ratios[row["matrix"]][row["method"]] = float(row["relative_error"]) / res
233
234     fig, ax = plt.subplots(figsize=(10, 6))
235     _grouped_bars(ax, matrices, methods,
236                  lambda mat, met: ratios.get(mat, {}).get(met))
237
238     # Riferimento: il rapporto err/res e' limitato superiormente da cond(A).
239     cond_map = {row["matrix"]: float(row["cond"]) for row in selected if "cond" in row}
240     for i, matrix_name in enumerate(matrices):
241         if matrix_name in cond_map:
242             ax.hlines(cond_map[matrix_name], i - 0.4, i + 0.4,
243                       color="black", linestyle="--", linewidth=1.2,
244                       label=f"cond(A)" if i == 0 else "_nolegend_")
245
246     ax.set_title(f"Amplificazione errore/residuo (tol = {tol_label})")
247     ax.set_xlabel("Matrice")
248     ax.set_ylabel(r"$\frac{\|x-x^*\|}{\|x^*\|} \frac{\|r\|}{\|b\|}$ ($\approx$ fattore di amplificazione)")
249     ax.set_yscale("log")
250     ax.set_xticks(range(len(matrices)))
251     ax.set_xticklabels(matrices)
252     ax.grid(True, axis="y", which="both", alpha=0.3)
253     ax.legend()

```

```

254     _save(fig, path)
255
256
257 # -----
258 # C) Costo per iterazione + bar chart riassuntivi.
259 # -----
260 def plot_cost_per_iter(rows: list[dict[str, str]], tol_label: str, path: Path) -> None:
261     import matplotlib.pyplot as plt
262
263     selected = [row for row in rows if row["tol"] == tol_label]
264     matrices = sorted({row["matrix"] for row in selected})
265     methods = _methods_present(selected)
266
267     cost = defaultdict(dict) # cost[matrix][method] = elapsed/iterations
268     for row in selected:
269         iters = int(row["iterations"])
270         if iters > 0:
271             cost[row["matrix"]][row["method"]] = float(row["elapsed_seconds"]) / iters
272
273     fig, ax = plt.subplots(figsize=(10, 6))
274     _grouped_bars(ax, matrices, methods,
275                   lambda mat, met: cost.get(mat, {}).get(met))
276     ax.set_title(f"Costo medio per iterazione (tol = {tol_label})")
277     ax.set_xlabel("Matrice")
278     ax.set_ylabel("Tempo per iterazione [s]")
279     ax.set_yscale("log")
280     ax.set_xticks(range(len(matrices)))
281     ax.set_xticklabels(matrices)
282     ax.grid(True, axis="y", which="both", alpha=0.3)
283     ax.legend()
284     _save(fig, path)
285
286
287 def plot_summary_bars(rows: list[dict[str, str]], tol_label: str, path: Path) -> None:
288     import matplotlib.pyplot as plt
289
290     selected = [row for row in rows if row["tol"] == tol_label]
291     matrices = sorted({row["matrix"] for row in selected})
292     methods = _methods_present(selected)
293
294     time_of = defaultdict(dict)
295     iter_of = defaultdict(dict)
296     for row in selected:
297         time_of[row["matrix"]][row["method"]] = float(row["elapsed_seconds"])
298         iter_of[row["matrix"]][row["method"]] = int(row["iterations"])
299
300     fig, axes = plt.subplots(2, 1, figsize=(10, 10))
301     _grouped_bars(axes[0], matrices, methods,
302                   lambda mat, met: time_of.get(mat, {}).get(met))
303     axes[0].set_title(f"Tempo di calcolo (tol = {tol_label})")
304     axes[0].set_ylabel("Tempo [s]")
305     axes[0].set_yscale("log")
306
307     _grouped_bars(axes[1], matrices, methods,
308                   lambda mat, met: iter_of.get(mat, {}).get(met))
309     axes[1].set_title(f"Iterazioni (tol = {tol_label})")
310     axes[1].set_ylabel("Iterazioni")
311     axes[1].set_yscale("log")
312
313     for ax in axes:
314         ax.set_xlabel("Matrice")
315         ax.set_xticks(range(len(matrices)))
316         ax.set_xticklabels(matrices)

```

```

317     ax.grid(True, axis="y", which="both", alpha=0.3)
318     ax.legend()
319     _save(fig, path)
320
321
322 # -----
323 # Main: genera i grafici di approfondimento dai CSV (e dalla riesecuzione dei
324 # solutori per la storia di convergenza).
325 # -----
326 def main() -> None:
327     args = parse_args()
328     output_dir = args.output
329     if not output_dir.is_absolute():
330         output_dir = BASE_DIR / output_dir
331     plots_dir = output_dir / "plots"
332     plots_dir.mkdir(parents=True, exist_ok=True)
333
334     rows = load_rows(output_dir / "results.csv")
335
336     bar_tol = _closest_tol(rows, args.bar_tol)
337
338     print("Genero i grafici dal CSV...")
339     plot_iter_vs_cond(rows, bar_tol, plots_dir / "iter_vs_cond.png")
340     plot_error_vs_residual(rows, bar_tol, plots_dir / "error_vs_residual.png")
341     plot_cost_per_iter(rows, bar_tol, plots_dir / "cost_per_iter.png")
342     plot_summaryBars(rows, bar_tol, plots_dir / "summaryBars.png")
343
344     print("Calcolo la storia di convergenza (rieseguo i solutori)...")
345     histories = compute_histories(args.conv_tol, args.max_iter)
346     plot_convergence(histories, args.conv_tol, plots_dir / "convergence.png")
347
348     print(f"\nGrafici scritti in: {plots_dir}")
349     for name in ("convergence.png", "iter_vs_cond.png", "error_vs_residual.png",
350                "cost_per_iter.png", "summaryBars.png"):
351         print(f" - {name}")
352
353
354 def parse_args() -> argparse.Namespace:
355     parser = argparse.ArgumentParser(
356         description="Grafici di approfondimento (MCS Assignment 1)")
357     parser.add_argument("--output", type=Path, default=Path("results"),
358                         help="Cartella con results.csv/cond.csv e output plots/, default results.")
359     parser.add_argument("--conv-tol", type=float, default=1e-10,
360                         help="Tolleranza per la storia di convergenza, default 1e-10.")
361     parser.add_argument("--bar-tol", type=float, default=1e-8,
362                         help="Tolleranza per i grafici a barre / cond, default 1e-8.")
363     parser.add_argument("--max-iter", type=int, default=20000,
364                         help="Numero massimo di iterazioni, default 20000.")
365     return parser.parse_args()
366
367
368 if __name__ == "__main__":
369     main()

```

7.4 test_assignment.py

```

1  """Small tests for the assignment code."""
2
3  from __future__ import annotations
4

```

```

5 from pathlib import Path
6 from tempfile import TemporaryDirectory
7
8 import numpy as np
9 from scipy.io import mmread
10 from scipy.sparse import diags
11
12 from solvers import SOLVERS, ConjugateGradient
13
14
15 def test_scipy_reads_matrix_market() -> None:
16     text = """%%MatrixMarket matrix coordinate real general
17 % tiny test matrix
18 3 3 5
19 1 1 2.0
20 1 2 -1.0
21 2 1 -1.0
22 2 2 2.0
23 3 3 3.0
24 """
25     with TemporaryDirectory() as tmp:
26         path = Path(tmp) / "tiny.mtx"
27         path.write_text(text, encoding="utf-8")
28         A = mmread(path).tocsr()
29
30     x = np.array([1.0, 2.0, 3.0])
31     assert np.allclose(A @ x, np.array([0.0, 3.0, 9.0]))
32     assert np.allclose(A.diagonal(), np.array([2.0, 2.0, 3.0]))
33
34
35 def test_solvers_on_tridiagonal_spd() -> None:
36     A = _tridiagonal_spd(20)
37     x_exact = np.ones(20)
38     b = A @ x_exact
39
40     for solver in SOLVERS:
41         result = solver.solve(A, b, tol=1e-8, max_iter=20000)
42         relative_error = np.linalg.norm(x_exact - result.x) / np.linalg.norm(x_exact)
43         assert result.converged, solver.name
44         assert relative_error < 1e-6, solver.name
45
46
47 def test_conjugate_gradient_is_fast_on_small_matrix() -> None:
48     A = _tridiagonal_spd(20)
49     x_exact = np.ones(20)
50     b = A @ x_exact
51     result = ConjugateGradient().solve(A, b, tol=1e-10, max_iter=20000)
52     assert result.converged
53     assert result.iterations <= 20
54
55
56 def _tridiagonal_spd(n: int):
57     return diags(
58         diagonals=[-np.ones(n - 1), 3 * np.ones(n), -np.ones(n - 1)],
59         offsets=[-1, 0, 1],
60         format="csr",
61     )
62
63
64 if __name__ == "__main__":
65     test_scipy_reads_matrix_market()
66     test_solvers_on_tridiagonal_spd()
67     test_conjugate_gradient_is_fast_on_small_matrix()

```

```
68 print("Tutti i test sono passati.")
```